第二届大学生数据要素素质大赛

基于网络爬虫与 NLP 的基金发行公告结构化信息提取研究

——以巨潮资讯网为例

摘要：

随着基金行业的迅速扩张，基金发行公告作为关键信息披露载体，其数量与复杂性不断提升，传统人工处理与基于规则的方法在效率与准确性方面存在显著局限。本文以巨潮资讯网基金发行公告为研究对象，构建了融合网络爬虫与自然语言处理（*NLP*）技术的结构化信息提取系统。研究设计了爬虫采集、*OCR* 兜底、表格解析、正则匹配与语义抽取等多层次方法，并提出“规则驱动+*NLP* 语义约束”的混合框架以提升系统鲁棒性。基于 459 份有效公告的实验结果表明，该方法能够在多样化文本格式下实现高准确度与高效率的信息抽取。研究进一步验证了该系统在投资决策支持、产品研究和智能监管等方面的应用价值。本文的贡献在于提出了一种面向金融文本的自动化抽取方法论，为后续引入深度学习与多模态模型奠定了技术基础。

关键词：基金发行公告、结构化信息提取、自然语言处理、网络爬虫

目录

一、项目概述 1
1.1 项目背景 1
1.2 应用领域场景 3
1.3 主要工作 5
1.3.1 数据采集与处理 5
1.3.2 结构化提取 5
二、解决方案 6
2.1 整体方案架构设计 6
2.1.1 系统总体流程 6
2.1.2 数据采集与预处理模块 7
2.1.3 基于 *NLP* 的信息提取模块 11
2.1.4 结果存储与校验模块 14
2.2 方案功能 15
2.2.1 基金公告信息提取功能 16
2.2.2 多格式文档的鲁棒解析与自适应处理功能 16
2.2.3 字段智能识别与语义抽取功能 16
2.2.4 数据清洗、规范化与逻辑校验功能 16
2.2.5 结果输出与导出功能 17
三、关键技术 17
3.1 数据采集详细介绍 17
3.2 数据算法分析 18
3.2.1 描述性统计分析 18
3.2.2 文本结构分析 19
3.3 可视化成果与系统展示 20
3.3.1 基金类型分布 20
3.3.2 年度发行趋势 21
3.3.3 基金管理人与托管人分析 22
3.3.4 运作方式分布 23
四、应用价值 24
4.1 经济效益分析 24
4.1.1 提升信息处理效率，降低人力成本 24
4.1.2 增强数据时效性，提升决策价值 25
4.1.3 支持规模化应用，产生规模效应 25
4.1.4 优化资源配置，提升核心竞争力 25
4.2 社会效益 26
4.2.1 提升金融市场信息透明度，保护投资者权益 26
4.2.2 赋能监管科技，提升监管效能 26
4.2.3 促进金融知识普及与投资者教育 27
五、系统优化与展望 27

一、项目概述

1.1 项目背景

在金融市场蓬勃发展的当下，基金行业作为重要组成部分，持续展现出强大的增长活力与巨大的市场潜力。行业规模不断扩张，产品类型日益丰富，实现了跨越式发展。

根据中国证券投资基金业协会（*AMAC*）数据显示（见图 1），截至 2025 年 6 月，我国公募基金管理人数量已达 164 家，存续产品数量为 12,905 只，资产管理总规模高达 34.39 万亿元[1]。从 2025 年 1 月到 7 月，公募基金的资产净值呈现出稳步增长的趋势，从 3193.2 亿元增长至 3507.6 亿元，增长率为 9.84%。尽管每月的增长率存在波动，但整体趋势是持续向上的。1 月的增长率为 0.92%，2 月略有下降至-0.03%，而从 3 月开始，增长率逐步回升，从 2.79%增加至 7 月的 1.99%。整个期间的平均资产净值为 3324.3 亿元（见图 2），这一数据反映了公募基金市场的健康增长，突显了市场参与的潜力和扩展的态势，进一步强调了基金发行公告的重要性和对数据结构化提取的迫切需求。在这一快速扩张的市场中，基金发行活动尤为频繁，每只新基金的设立都需发布相应的发行公告。这些公告是基金发行过程中至关重要的信息载体，详细涵盖了基金名称、发行时间、基金管理人、基金托管人、基金类型、募集规模、认购费率、申购费率、赎回费率等诸多核心数据要素[2]。它们不仅为投资者、监管机构及金融信息服务机构提供了关键的决策依据，也由于其海量、非结构化的文本形态，凸显出对其进行智能化、结构化信息提取的巨大价值与迫切需求。

然而，随着近几年基金行业的繁荣发展，基金发行公告的数量呈爆发式增长。仅巨潮资讯网这一重要的金融信息披露平台，每日更新的基金相关公告就数以百计。这些公告不仅数量庞大，而且格式多样，多以 PDF 文档形式呈现，包括招募说明书、基金合同、托管协议、发售公告等。其内容结构复杂，既有规整的表格，也有大篇幅的非结构化文字段落。这种海量且格式多样的特性，使得从基金发行公告中精准提取结构化信息，成为金融信息服务机构、基金研究平台亟待解决的核心问题。

面对大规模的公告数据，传统的人工提取信息方式效率低下，且易受人为因

素干扰，导致信息提取的准确性和一致性难以保证。例如，一家中型金融信息服务机构，在处理每日新发布的基金公告时，若采用人工方式，需投入大量人力，且完成全部公告信息提取往往需要耗费数天时间，期间还可能因人工疲劳、理解偏差等出现信息错漏。因此，利用自然语言处理（*NLP*）技术来处理这些信息，成为提升提取效率和准确性的关键。

从技术角度看，过往一些简单的数据抓取和文本处理方法，在应对基金公告这类复杂文本时，也暴露出诸多局限性。常规网络爬虫在处理 PDF 格式文档时，常因格式转换问题导致信息丢失或乱码，难以完整获取公告中的全部内容。而早期基于规则的文本信息提取技术，面对公告格式的多样性和文本表述的灵活性，规则制定难度大，覆盖率低，一旦公告格式或表述出现变化，便无法准确提取信息。这里，*NLP* 技术的应用能够有效解决这些问题，通过基于语义理解和上下文分析的方式，帮助提取出基金名称、基金代码、基金管理人等关键信息，极大地提升了信息提取的灵活性与准确性。

在信息时代，数据的价值不言而喻。准确、及时地获取基金发行公告中的结构化信息，对于投资者而言，能辅助其快速筛选符合自身投资目标和风险偏好的基金产品，做出更为明智的投资决策；对于金融信息服务机构来说，可利用 *NLP* 技术提升其信息服务的质量与效率，增强市场竞争力；对于监管机构，有助于实时、全面地掌握基金发行动态，加强市场监管力度，维护金融市场的稳定秩序。因此，开发一种高效、精准的基金发行公告结构化信息提取方法迫在眉睫。*NLP* 技术的兴起与发展，尤其是在命名实体识别、文本分类、情感分析等方面的创新，为解决这一难题提供了新的契机与可能。本研究正是基于此背景，尝试融合网络爬虫与 *NLP* 技术，以巨潮资讯网的基金发行公告为研究对象，探索一套切实可行的结构化信息提取方案[3]。

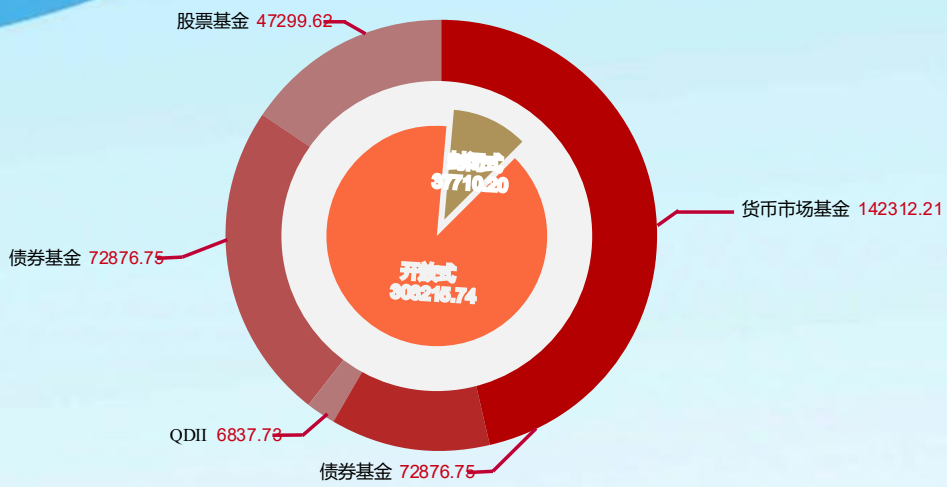


图 1 公募基金市场数据（单位：亿元）

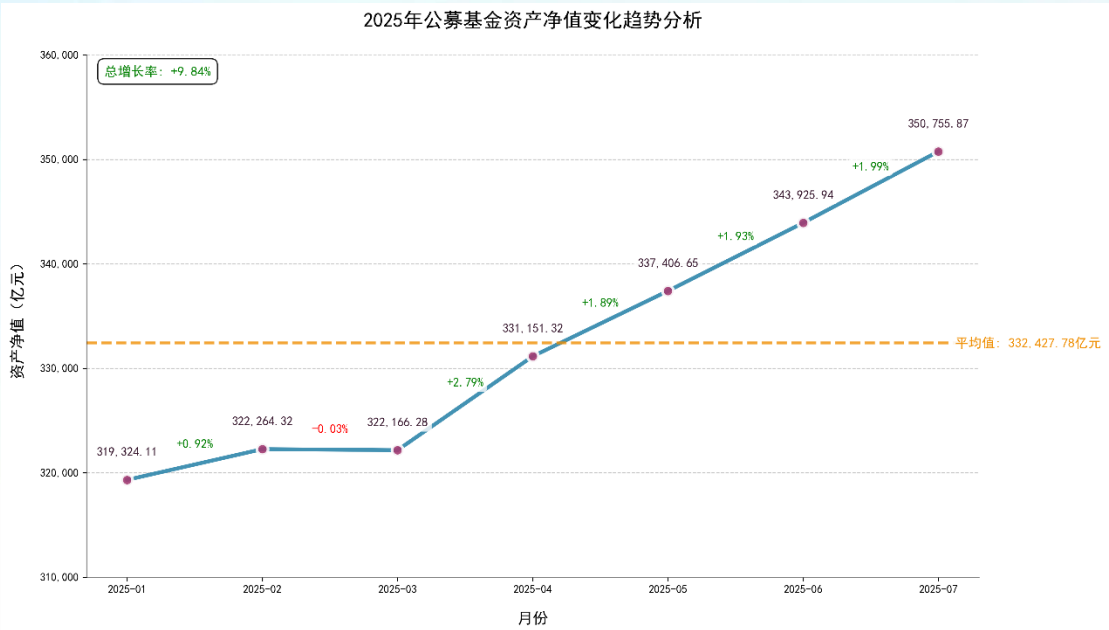


图 2 2025 年 1-7 月公募基金资产净值变化趋势

1.2 应用领域场景

本研究针对基金发行公告的结构化信息智能提取，其应用价值深远，广泛渗透于金融市场的各个核心环节，为不同层面的市场参与者提供关键的数据支撑，从而驱动效率提升、风险控制与决策优化。对于个人投资者而言，基金发行公告虽是了解产品最权威的窗口，但其冗长、专业的文本形态构成了较高的信息门槛。智能提取技术能够将复杂的公告文本转化为清晰易懂的关键数据表

格，直接赋能于各类理财平台，帮助投资者快速掌握产品的核心信息。这不仅提升了投资者的信息获取效率，还降低了分析难度，使他们能够在繁杂的市场中做出更加明智和及时的投资决策。

在机构层面，如基金公司、券商研究所或银行理财子等专业角色，及时准确地获取并分析全市场发行数据是进行产品设计、竞品跟踪和策略研究的基础。传统人工处理方式效率低下，难以应对市场高速的产品创新节奏。本研究技术可助力机构快速响应市场热点：例如当“碳中和”“高端制造”等主题成为市场焦点时，研究团队可通过系统瞬间提取并统计近期所有相关主题基金的募集规模、托管行、费率结构等关键信息，从而为自身产品的定位、定价和推广策略提供精准的数据参考，高效抓住发行时间窗口，赢得市场竞争先机。

对于监管机构而言，维护市场信息披露的真实性、准确性与完整性是其核心职责[4]。面对海量且格式不一的公告文档，传统人工抽查方式覆盖面有限，效率亟待提升。本研究的自动化提取技术能够为监管科技体系提供重要的数据底层支持：通过将非结构化的公告文本转化为标准化的结构化数据，为后续的智能分析奠定坚实基础[5]。这一技术可为构建自动核查系统提供关键数据支撑，例如未来可基于提取的数据开发比对系统，检测不同公告中是否存在关键信息矛盾。虽然完整的智能监管决策仍需结合更复杂的规则引擎与知识图谱，但本研究实现的结构化信息提取作为前端基础环节，能够显著提升数据处理的规模化能力，为监管模式从“事后抽查”向“事中监测”与“事前预警”转型提供可能，从而助力全面提升监管的穿透性与效率。

此外，在金融信息服务业中，万得、同花顺等数据服务商的竞争力极大程度上依赖于数据的广度、速度与准确性。基金发行数据作为其关键数据产品之一，目前仍高度依赖人工录入与复核。集成自动化信息提取系统后，可构建端到端的数据流水线——从公告抓取、解析、校验到发布，实现分钟级别的数据更新换代，彻底替代传统耗时费力的人工操作模式。这不仅极大提升了数据的时效性，更使数据工程师能聚焦于开发更具价值的深度分析工具与可视化产品，从而为高端机构客户提供更优质的决策支持服务，推动整个行业的数据服务模式向智能化、实时化迈进。

可见，基金发行公告的智能信息提取技术作为连接非结构化文本与结构化数据的关键桥梁[6]，其应用场景贯穿投资决策、产品研究、监管风控与数据服务等多个核心领域，不仅具有显著的经济效益，也是构建未来智能金融基础设施的重要一环。

1.3 主要工作

1.3.1 数据采集与处理

为实现对基金发行公告的结构化信息提取，本研究首先完成了数据的采集与预处理工作，为后续算法模型提供了高质量的数据基础。本研究的数据源为巨潮资讯网（www.cninfo.com.cn）的基金公告专题板块。我们设计并实现了专用的网络爬虫程序来爬取 2025 年份的基金发行公告 PDF 文档，共计 745 份，构建了本研究的初始数据集。然后对这些数据进行数据预处理，数据清洗、删除不可用数据等操作，经过处理后的 PDF 文档共计 459 份。

1.3.2 结构化提取

在基金公告的结构化信息提取过程中，本文设计了多个关键步骤，确保从 PDF 文件中准确抽取出各种重要的基金数据。

首先通过 pdfplumber 和 PyPDF2 解析 PDF 文本与表格，对扫描版文档采用光学字符识别（*OCR*）技术进行兜底识别。接着，利用正则表达式与关键词匹配，从正文与表格中提取基金名称、代码、发行日期、管理人与托管人名称、基金类型、运作方式、募集规模及费率等字段。针对机构名称跨行、费率表述多样等情况，设计了多行拼接、语义纠偏、分段费率解析等策略，并结合文件名信息进行补充校验[7]。

最终，提取结果经清洗与规范化后输出为结构化 CSV 格式，支持后续分析与可视化应用。该系统在保证提取准确性的同时，具备较强的鲁棒性与可扩展性。

二、解决方案

2.1 整体方案架构设计

2.1.1 系统总体流程

在基金发行公告数据的处理过程中，整个系统的设计包括了数据采集、信息提取和结果存储几个关键模块。系统架构采用了模块化的方式，每个模块的功能都与数学模型和算法密切关联，以保证系统的稳定性和高效性。以下是系统流程的详细描述：

首先，数据采集模块是基金公告处理的起点，主要任务是通过爬虫技术从指定网站抓取相关的基金公告文件。系统使用了动态爬虫技术，通过 requests 库结合重试机制（Retry 和 HTTP Adapter）确保数据的稳定获取。爬虫获取到的文件格式主要为 PDF，系统通过对 *URL* 进行解析，下载符合条件的公告文件。

随后，在信息提取模块中，系统通过 *OCR* 技术、表格解析、正则表达式等手段，从 PDF 文档中提取出基金公告中的关键信息。该模块不仅关注文本信息的提取，还特别重视表格信息的处理和费用信息的精准提取。具体步骤包括：

（1）表格信息提取：通过 pdfplumber 和 PyPDF2 等库，对 PDF 中的表格进行解析，提取基金名称、代码、募集规模等字段。

（2）*OCR* 识别：对扫描版 PDF 或无法直接提取文本的文件，系统会启用 OCR 技术（Tesseract 引擎）将扫描图像中的文字转换为文本数据。

（3）文本数据清洗：使用正则表达式和文本清洗方法对提取的文本进行格式化，去除无关符号和多余空格，确保数据的整洁性和一致性。

数据存储模块的主要任务是将提取的数据进行结构化存储，并对数据进行校验，确保提取结果的准确性。例如，系统会检查基金名称、基金代码等字段的合法性，并进行逻辑校验，如基金名称是否与基金代码一致。最终，所有提取的数据将被存储在 CSV 文件中，方便后续分析和查询。

整个过程通过自动化脚本完成，保证了数据采集、信息提取和存储的高效性。系统不仅在文档的结构化信息提取上进行了优化，还在 *OCR* 和表格解析的精确度上作了调整，以应对各种不同格式和内容的基金公告文件。具体流程见图 3。

2.1.2 数据采集与预处理模块

数据采集与预处理模块承担了从网站爬取基金公告 PDF 文件、解析文件内容、清洗数据并进行格式化的任务。由于 PDF 文件格式较为复杂，包含了非结构化文本和结构化表格数据，因此该模块不仅使用了爬虫技术来获取数据，还结合了文本清洗、正则表达式、*OCR* 识别等技术，确保数据能够为后续的自然语言处理和信息提取提供准确的输入（见图 4）。

（1）数据采集（爬虫模块）

数据采集的核心任务是通过网络爬虫从指定网站（如巨潮资讯网）自动抓取基金公告的 PDF 文件。爬虫系统需要处理反爬虫机制、分页爬取等问题，确保数据的稳定和高效抓取。

请求构建与动态处理网络连接：在请求构建中，爬虫通过动态请求头来伪装请求来源，避免被网站识别为爬虫。请求的过程可以用如下公式表示：

$$P = \mathrm{Re}quest(U, H, D) \tag{1}$$

其中，P表示请求，U为目标 *URL*，H为请求头（包括 User-Agent 等信息），D为请求数据（如时间范围、关键词等）。

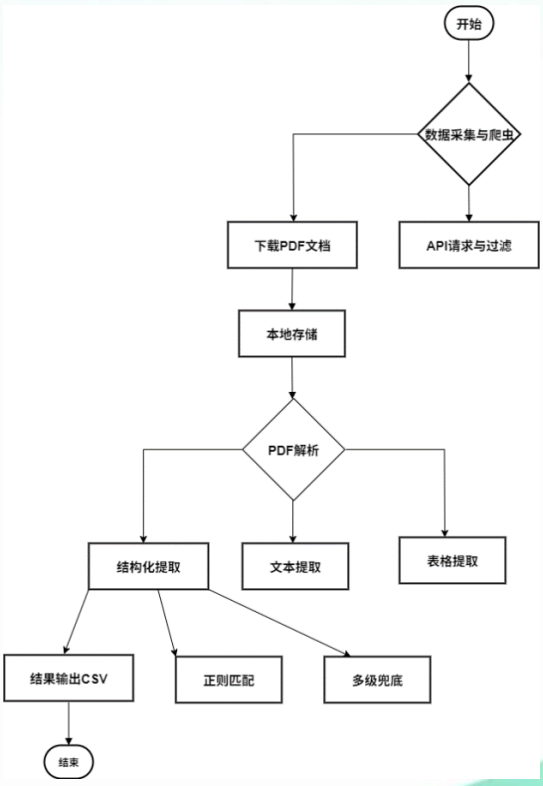


图 3 系统总体流程

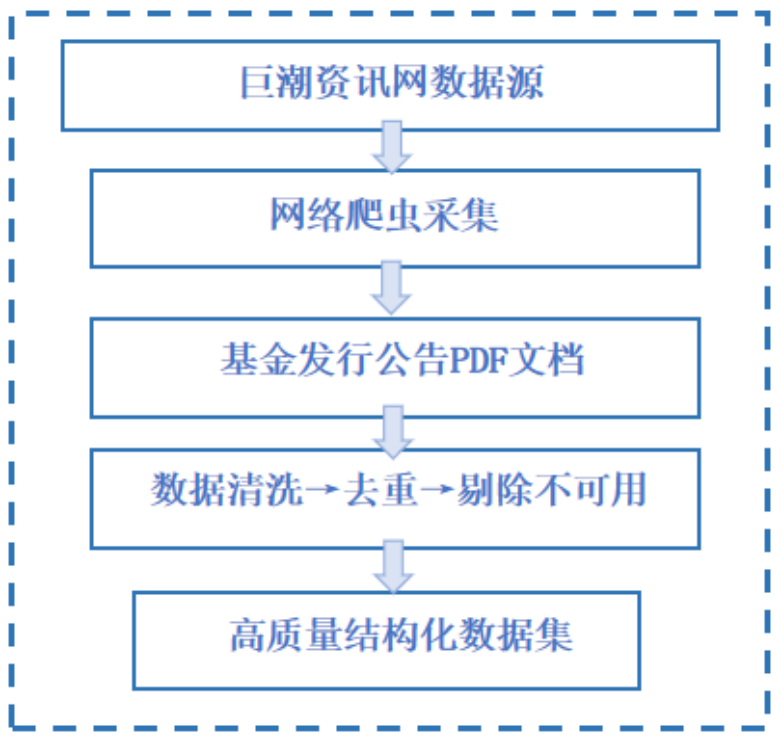


图 4 数据采集与预处理流程

分页爬取与数据筛选：爬虫通常按页数分页爬取数据。每页请求的数据量为 N，如每页显示 30 条公告数据。分页请求公式为：

$$P_n = \mathrm{Re}quest(U_n, H, D_n) \tag{2}$$

其中，P_n 表示第 n 页的请求，U_n 为第 n 页的 URL，D_n 为第 n 页的请求参数。

文件下载：一旦找到目标公告的 PDF 文件，爬虫通过下载链接下载文件，文件名可以通过如下方式生成：

$$F = Generate_Filename(T, C) \tag{3}$$

其中，T为公告发布日期，C为基金名称或代码，F为最终生成的文件名。

(2) PDF 文档解析与文本提取

在获取到 PDF 文件后，系统需要提取文件中的文本信息。PDF 文件中的文本信息可以是非结构化的（如正文文本），也可以是结构化的（如表格数据）。提取过程分为表格数据提取、文本提取和 OCR 识别三个步骤。

表格数据提取：表格数据提取通过 pdfplumber 库来实现，它能够解析 PDF 中表格的结构，并将表格中的数据转化为键值对。表格数据提取过程的数学模型可以表示为：

$$T_{table} = \{F_1:V_1, F_2:V_2, \cdots, F_n:V_n\} \tag{4}$$

其中，F_1，F_2，…，F_n 代表表格中的字段名（如“基金名称”、“基金代码”），而 V_1，V_2，…，V_n 代表相应的字段值（如具体的基金名称和代码）。

文本数据提取：

对于非结构化文本数据，系统通过 PyPDF2 库从每一页提取文本。提取过程的数学公式可以表示为：

$$T_{text} = \sum_{i=1}^{n} Extract_Text(P_i) \tag{5}$$

其中，T_{text} 是从所有页面中提取的文本数据，$Extract_Text(P_i)$ 表示从第 i 页 PDF 中提取的文本内容，n 为 PDF 文件的总页数。

***OCR* 识别：**对于扫描版 PDF，系统通过 *OCR* 技术提取图像中的文本。*OCR* 过程可以表示为：

$$T_{OCR} = OCR(I) \tag{6}$$

其中，I 为图像数据（来自 PDF 的扫描页面），T_{OCR} 为 *OCR* 引擎提取的文本内容。

（3）数据清洗与预处理

提取的文本数据往往包含无关的符号、格式错误、乱码等噪声，需要进行数据清洗与预处理。数据清洗的数学模型和处理过程可以分为多个步骤：

去除无关符号与多余空格：在文本中去除无关符号并将多余的空格合并为一个空格。清洗公式为：

$$T_{clean} = Clean(T_{raw}) \tag{7}$$

其中，T_{raw} 为原始文本，T_{clean} 为清洗后的文本。

合并断行与多余空格：由于 PDF 的文本排版，提取出来的文本往往包含无意义的换行符和空格。合并空白和断行的公式为：

$$T_{merged} = Collapse(T_{clean}) \tag{8}$$

其中，T_{merged} 为合并后的文本。

日期格式统一：

在提取的文本中，日期格式不统一。系统通过正则表达式统一日期格式。日期统一的公式为：

$$D_{standard} = Format_Date(D_{raw}) \tag{9}$$

其中，D_{raw} 为原始日期格式，$D_{standard}$ 为标准化之后的日期格式。

公司名称清洗：

在文本中提取的公司名称通常会有多种格式（如“天弘基金管理有限公司基金管理人”或“中国建设银行股份有限公司”）。系统通过正则表达式和清洗方法对其进行标准化，清洗过程公式为：

$$C_{clean} = Clean_Conpany(C_{raw}) \tag{10}$$

其中，C_{raw} 为原始公司名称，C_{clean} 为清洗后的公司名称。

（4）数据存储与校验

清洗后的数据需要进行存储，并对数据进行校验以确保准确性。数据存储的公式如下：

$$S_{data} = \{rund_name, fund_code, issue_date, \cdots\} \tag{11}$$

其中，S_{data} 为存储的数据，包含基金名称、基金代码、发行时间等字段。每个字段的数据需要通过逻辑校验和格式校验，确保数据的有效性。

字段合法性校验：

系统会检查每个字段的数据是否符合预期的格式。例如，基金代码应为 6 位数字，日期应符合 *YYYY-MM-DD* 格式。这些合法性校验可以表示为：

$$Check_Field(F) \rightarrow \{True\ if\ vaild, False\ othwise\} \tag{12}$$

其中，$Check_Field(F)$表示对字段F的合法性检查，返回 True 表示有效，False 表示无效。

逻辑校验：

除了格式校验，系统还会进行逻辑校验，例如基金名称和基金代码是否匹配。逻辑校验的公式为：

$$Check_Logic(F_1, F_2) \rightarrow \{True\ if\ F_1\ \ and\ F_2\ \ match,\ False\ otherwise\} \quad (13)$$

其中，$Check_Logic(F_1, F_2)$表示基金名称和基金代码的逻辑校验。

数据存储：

校验后的数据将被存储为结构化的 CSV 文件，文件格式可以表示为：

$$D_{final} = \{fund_name, fund_code, issue_date, \cdots\} \quad (14)$$

其中，D_{final}为最终存储的数据，所有字段数据均经过合法性和逻辑校验。

通过这些步骤，数据采集与预处理模块实现了从 PDF 文件中获取和清洗数据的全过程，并确保了数据的高质量和高一致性，为后续的信息提取和分析提供了可靠的数据支持。

2.1.3 基于 *NLP* 的信息提取模块

本模块是系统的核心，承担着从预处理后的文本中精准提取 12 类关键字段（文件名、基金名称、基金代码、发行时间、基金管理人名称、基金托管人名称、基金类型、运作方式、募集规模、认购费率、申购费率、赎回费率）的任务。在本模块中使用了 *NLP* 技术来提升基金公告数据提取的准确性和效率。*NLP* 技术的核心作用在于通过语义理解、上下文分析和实体识别来帮助识别基金公告中的关键字段（见图 5）。基金公告通常包含多样化的文本结构和复杂的表格数据，*NLP* 的引入使得提取过程不仅更加自动化，而且在面对不同格式或表述方式时也具备了更强的适应能力。

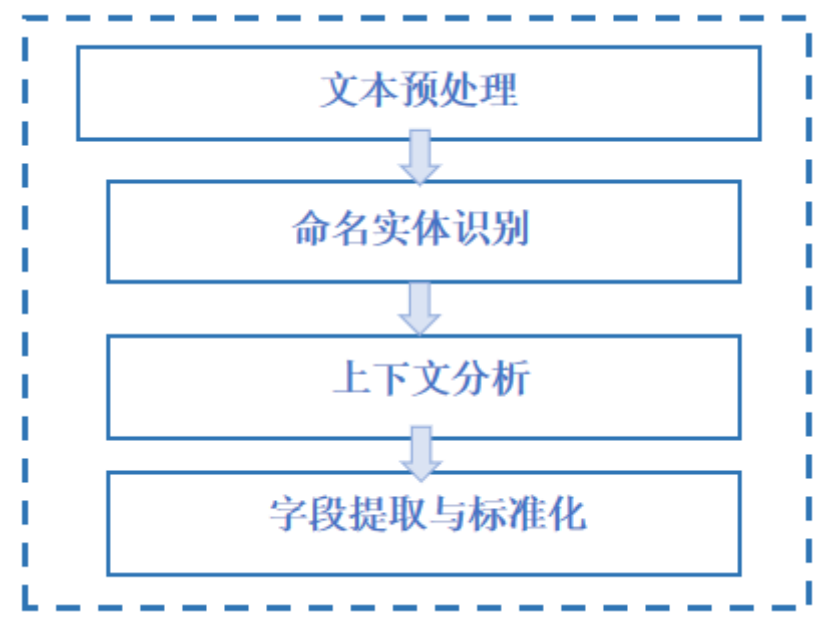


图 5 基于 NLP 的信息提取流程

基金公告文本往往包含多源异构信息（正文段落、表格数据、特殊排版），因此本研究将抽取过程建模为一个典型的**信息提取问题**。给定原始文本集合$\tau = \{t_1, t_2, ..., t_n\}$，目标是构建一个映射函数

$$F: \tau \to S \tag{15}$$

其中$S = \{s_1, s_2, ..., s_m\}$表示基金公告的结构化要素集合，包括基金名称、基金代码、管理人、托管人等

为了实现改映射，本文采用“规则驱动+*NLP* 语义约束”的混合抽取框架，具体包括以下模块：

（1）基金名称与基金代码的识别可抽象为命名实体识别子任务：

$$\hat{s}_{name} = arg\max_{s \epsilon C_{name}} P(s|t) \tag{16}$$

$$\hat{s}_{code} = arg\max_{s \epsilon C_{code}} P(s|t) \tag{17}$$

其中C_{name}, C_{code}分别表示候选实体集合。候选实体由正则模版生成（如“六位数字”对应基金代码）；通过上下文窗口约束$W(t)$提高精度，即若实体出“基金代码：”附件，则其置信度权重提升：

$$P(s|t) = P_{regex}(s) + \lambda \cdot I(s \epsilon W(t)) \tag{18}$$

（2）机构名称识别与角色消歧

基金管理人/托管人的抽取属于实体消歧问题。设候选机构集合为$C_{org} = \{o_1, o_2, ..., o_k\}$，是角色（管理人/托管人）记为标签$y \epsilon \{0, 1\}$。通过一下目标函数确定最优匹配：

$$\hat{o} = arg\max_{o \epsilon C_{org}} [P_{regex}(o) + \alpha \cdot P_{dict}(o) + \beta \cdot P_{ctx}(o)] \tag{19}$$

其中：

$P_{regex}(o)$：正则模板置信度；

$P_{dict}(o)$：是否在金融机构词典中的匹配概率；

$P_{ctx}(o)$：基于上下文窗口的角色判别：

α，β：超参数，反映不同约束的权重。

（3）日期归一化

设原始日期字符串为d_{raw}，归一化函数为：

$$g：d_{raw} \to d_{std} \tag{20}$$

其中d_{std}为 ISO 8601 格式标准日期。

例如：

$$g(“2020年5月1日”) = 2020 - 05 - 01 \tag{21}$$

$$g(“2020/05/01”) = 2020 - 05 - 01 \tag{22}$$

该过程对应于 *NLP* 中的 *Normalization* 子任务。

（4）费率抽取与数值化标准

设费率文本为r_{raw}，设对应的数值表示为$r \epsilon [0, 1]$。通过以下映射实现标准化：

$$h：r_{raw} \to r，h(“1.5\%”) = 0.015，h(“免收”) = 0 \tag{23}$$

当存在区间型费率（如“100万元以下1.5%,以上1%”），可建模为分段函数：

$$h(x)=\begin{cases}0.015, & x<10^6\\ 0.010, & x>10^6\end{cases} \tag{24}$$

（5）表格信息抽取

公告表格中的要素抽取可形式化为二维单元格映射问题：

$$M{:}C_{cell}\rightarrow S \tag{25}$$

其中C_{cell}为表格单元格集合，S为结构化要素集合。

映射过程分为定位和赋值两步。定位通过关键字匹配确定表格标题和行列标签；赋值是将单元格内容映射至相应要素，若冲突则按优先级策略解决。

2.1.4 结果存储与校验模块

在结果存储与校验模块中，首先对提取到的基金公告数据进行存储和规范化处理。所有经过校验和纠偏的数据将被存储在 CSV 文件中，方便后续的查阅与分析。通过这些步骤，系统有效提高了数据提取和存储的准确性，确保了结果的可靠性和一致性。所有提取出的结构化数据最终以 CSV 格式进行规范化输出和存储。每条记录均包含原始 PDF 文件名、各字段的提取结果及其状态标记，形成一个完整、清晰且易于后续分析的结构化数据集。通过将提取的关键信息规范化为统一的格式，系统保证了数据在存储过程中的一致性与可操作性（见图 6）。

为确保数据的准确性与一致性，系统实现了严格的校验与纠偏机制。首先，系统会对提取的字段进行逻辑校验，确保提取的数据符合业务规则。例如，基金代码应为 6 位数字，发行时间应在合理范围内，基金类型应为标准类别等。对于出现不符合规则的字段，系统会自动标记并进行纠偏操作。对于某些日期字段，系统会自动将不同格式的日期转化为统一格式，确保所有日期字段符合标准化要求。系统还具备一定的人工干预接口，能够让用户手动修正无法自动纠偏的特殊数据，进一步提高了数据的准确性和可靠性。

在数据存储方面，系统使用了高效的存储结构，确保数据能够快速查询与读取。系统通过建立索引机制，使得用户能够根据基金名称、基金代码等字段进行快速检索。同时，系统还具备增量存储功能，可以在新的基金公告数据提取完成后，将新增数据以增量方式存储，而不会影响现有数据的完整性。此功

能大大提高了数据存储的灵活性和扩展性，为后续的数据分析和决策支持提供了便捷的服务。

该模块采用模块化架构设计，使得系统在处理海量、异构公告时具备高度的可靠性、可扩展性与可维护性。每个模块都可独立运行并进行升级，能够应对不同格式公告的处理需求，并支持未来更多功能的扩展。通过这种灵活的架构，系统能够在不断变化的数据环境中稳定运行，并为未来的技术更新和功能拓展提供了强有力的支持。

通过这一系列设计，结果存储与校验模块确保了数据提取结果的高准确性、高一致性和高可用性，为基金公告的后续分析、查询与决策提供了可靠的技术保障，同时为金融信息服务的智能化升级提供了坚实的基础。

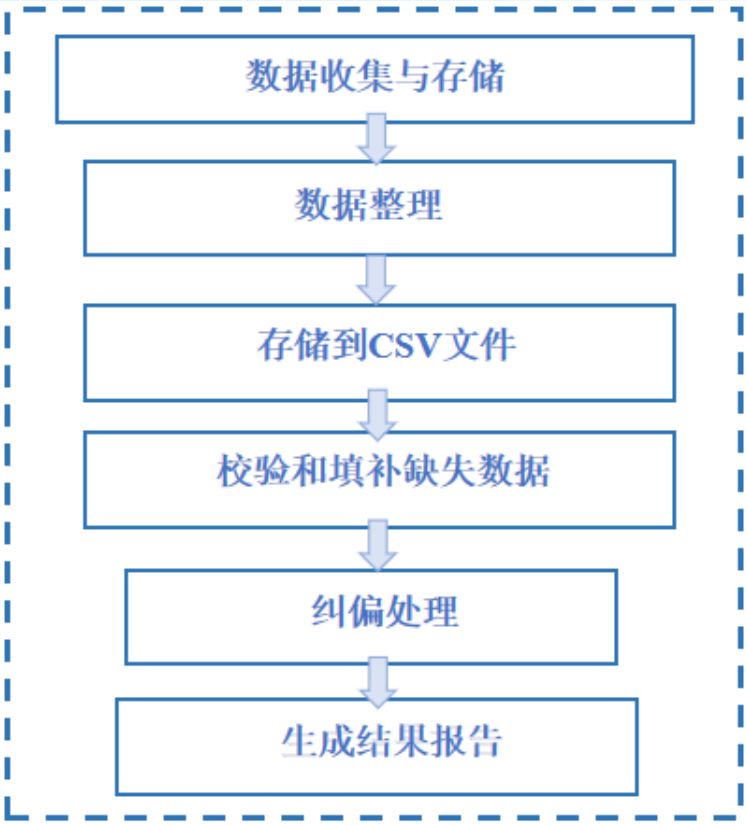


图 6 结果存储与校验流程

2.2 方案功能

本系统旨在为用户提供一套完整、高效、准确的基金公告信息处理解决方案，其核心功能围绕自动化信息提取、智能化数据处理与标准化结果输出三大维度展开，具体功能描述如下：

2.2.1 基金公告信息提取功能

本系统的基金公告信息提取功能是其核心之一，旨在通过自动化技术提升数据处理的效率与准确性。该功能首先依赖于网络爬虫技术，从多个金融信息平台（如巨潮资讯网等）自动抓取基金公告的 PDF 文件。爬虫程序通过定向爬取指定网页，结合多线程和异步下载技术，高效地批量下载基金公告的 PDF 文件，保证在较短的时间内获取到大量的基金公告数据。该功能的实现不仅大幅度提高了数据提取的效率，降低了人工操作的工作量，而且减少了由于人为疏忽造成的信息遗漏和错误，确保基金公告数据的及时更新和准确提取。通过这一自动化的信息提取功能，系统能够快速响应基金公告的发布，为后续的数据分析、查询与决策支持提供可靠的数据基础。

2.2.2 多格式文档的鲁棒解析与自适应处理功能

系统具备强大的格式兼容性，能够自适应处理不同版式、不同编码质量的 PDF 文件。对于常规文本型 PDF，可高精度保持原文结构与表格格式；对于扫描件或特殊编码文档，集成的 *OCR* 功能可确保文字内容的有效识别，全面保障了输入数据的完整性与可处理性。

2.2.3 字段智能识别与语义抽取功能

这是系统的核心功能，能够从冗长的公告全文中有针对性地定位、识别并抽取 11 类关键数据要素。该功能不仅支持对规整表格信息的精准抓取，还能够基于自然语言处理技术，从段落文本中通过语义模式匹配提取字段内容。特别针对金融公告中常见的特定表述（如“不超过 0.5%”、“募集规模约为 20 亿元”等）进行了优化，确保信息抽取的准确率和覆盖率。

2.2.4 数据清洗、规范化与逻辑校验功能

系统对提取出的原始信息并非简单输出，而是内置了强大的后处理能力。它能自动对提取内容进行清洗，去除无关符号和乱码；对日期、费率、规模等字段进行格式统一与标准化；并执行基本的逻辑校验（如验证基金管理人与托管人是否不同），从而保障了输出数据的规范性与可靠性。

2.2.5 结果输出与导出功能

系统最终提供规范、清晰的数据输出功能。所有提取结果将以标准化的CSV 格式生成结构化数据表，每条记录均与源文件准确对应，方便用户进行后续的归档、查询与多维分析。

综上所述，本系统集自动化、智能化与规范化为一体，其功能设计直击从非结构化公告文本中高效获取清洁、可信结构化数据的核心需求，为用户提供了端到端的解决方案。

三、关键技术

3.1 数据采集详细介绍

在合法合规的前提下，本研究的数据采集工作以中国证监会指定的信息披露网站——巨潮资讯网（www.cninfo.com.cn）为核心数据源。该平台提供的基金发行公告信息具有权威性、全面性和及时性特点，为研究提供了可靠的数据基础。

为实现对基金发行公告的结构化信息提取，我们设计并实现了一套专用的网络爬虫程序。该程序通过深入分析巨潮资讯网的公告查询接口，采用多参数组合轮询策略，精准定位并爬取了涵盖基金招募说明书、基金合同、发售公告等多种类型的基金发行公告 PDF 文档，成功构建了本研究的初始数据集，共计745 份有效公告。

在数据采集过程中，系统集成了多项稳健性设计：首先，通过实现自动重试机制和指数退避策略，有效应对网络异常和服务端限制，保障了长时间大规模采集任务的稳定性；其次，采用动态 *User-Agent* 池和完整请求头模拟技术，显著降低了被反爬机制识别的风险；最后，通过内置实时内容过滤系统，基于预设的关键词组合对公告标题进行双重判断，在采集源头即实现了无关公告的过滤和目标文档的筛选，极大提升了数据纯度和采集效率。

获取 PDF 文档后，我们采用 Python 编程语言及相关库对文档进行解析和关键信息提取。针对每份公告，程序自动搜索并提取一系列预定义的关键数据字段，主要包括：文件名、基金名称、基金代码、发行时间、基金管理人名称、基金托管人名称、基金类型、运作方式、募集规模、认购费率、申购费

率、赎回费率等。在提取过程中，对于公告文中未提及的字段，系统自动将其值设置为空（NULL），以确保数据的真实性与一致性。

所有提取出的信息经过清洗和标准化处理后，被转换为结构化的 CSV 数据格式，并存入数据库中进行规范化存储，形成了一个便于后续查询、分析与模型训练的结构化数据集，为研究工作提供了可靠的数据支撑。这一完整的数据采集与处理流程，不仅保证了数据质量，也为后续的结构化信息提取奠定了坚实基础。

3.2 数据算法分析

3.2.1 描述性统计分析

在数据算法分析部分，描述性统计分析为我们把握基金发行公告的数据特征提供了重要基础。通过对巨潮资讯网爬取公告的系统性分析，我们发现公告文本长度存在显著差异：招募说明书通常长达数百页，而发售公告等文件则较为精简[8]。这一发现直接影响算法设计，促使我们针对不同长度的文档采用差异化处理策略。

我们开发了专门的统计模块来自动化分析关键字段的分布特征。分析表明，基金名称、代码等基础信息大多出现在文档前部的固定位置，而费率、规模等字段则分布较为分散。这些统计结果直接指导了算法策略的制定：对位置固定的字段采用基于规则的快速提取，对分散字段则采用基于语义理解的深度提取方法。

通过分析基金类型与文本特征的关系，我们发现不同类型基金的信息披露存在明显差异。股票型基金公告通常较债券型基金更为详细，不同管理人的公告格式也各具特点。这些发现为设计针对性提取规则提供了依据，使算法能更好地适应多样化的公告格式。

我们还引入了可视化分析工具，通过分布直方图等图表直观展示数据特征，帮助快速识别异常情况和数据规律。这种可视化分析不仅提升了数据理解效率，也为算法参数的优化提供了直观参考。

基于这些统计分析结果，我们建立了数据驱动的算法优化机制。通过持续监控新公告的数据特征，系统能够自适应调整处理策略，保持对市场信息披露

模式变化的敏感性。这种动态优化能力确保了系统在处理各类公告时都能保持较高的准确性和效率。

描述性统计分析在本研究中发挥了关键作用，它将数据特征与算法设计紧密结合，为后续信息提取系统的优化提供了科学依据。通过这种方法论，我们不仅深入理解了基金公告的数据特性，更建立了一个能够持续自我完善的处理系统，为高效准确的结构化信息提取奠定了坚实基础。

3.2.2 文本结构分析

在文本结构分析环节，我们基于描述性统计的分析结果，对基金公告的内部组织规律进行了深入挖掘。通过系统研究大量公告样本，我们发现尽管不同基金管理人发布的公告在具体格式上存在差异，但整体上都遵循着相对稳定的结构化特征。这一发现为后续的信息提取算法设计提供了重要指导。

在算法实现层面，我们开发了专门的文本结构解析模块。该模块首先通过基于规则的模式匹配方法识别文档中的章节标题，利用正则表达式匹配常见的标题模式（如"第一章"、"第一节"、"一、"等数字编号模式，以及"基金的基本情况"、"基金管理人"等固定标题文本）。同时，模块还集成了基于字体大小和格式的启发式规则，能够识别视觉上突出的标题文本。这种多策略结合的标题识别方法显著提升了对不同格式公告的适应性。

针对表格数据的提取，我们采用了基于 pdfplumber 库的表格检测和解析算法。该算法不仅能够识别明显的表格边框，还能通过分析文本的位置对齐关系来重建无边框表格的结构。我们特别优化了跨页表格的处理能力，通过检测表头重复模式和内容连续性判断，实现了跨页表格的正确拼接。这对于提取基金费率、规模等关键数据至关重要。

在结构理解方面，我们构建了一个基于章节重要性的权重分配模型。通过分析发现，前部章节（如"重要提示"、"基金概要"）包含关键信息的概率显著高于后续章节。因此，算法会优先处理文档前三分之一的内容，并对此部分的文本进行更精细的分析。同时，我们对不同类型的公告建立了特征模板，例如招募说明书通常包含详细的投资策略章节，而发售公告则重点呈现销售安排信

息。这些模板为算法提供了先验知识，指导其在不同类型的公告中寻找特定信息。

通过将结构分析结果与文本内容处理相结合，我们的系统能够更智能地定位和提取目标信息。例如，当需要提取基金管理人信息时，算法会优先在"基金管理人"章节中搜索，并重点处理该章节内的表格和段落文本。这种基于结构的定向提取策略不仅提高了处理效率，也显著提升了提取准确率。

文本结构分析的结果还为后续的信息验证和补全提供了重要依据。当从正文中提取的信息存在不确定性时，系统会参考该信息在文档结构中的位置及其周边文本特征进行交叉验证。这种结构化的验证机制有效降低了误提取的风险，确保了最终输出数据的可靠性。

3.3 可视化成果与系统展示

在完成基金公告文本的结构化提取后，为了更直观地展示分析结果并辅助后续研究，我们基于处理后的数据开展了多维度的可视化工作。本部分主要展示了基金类型分布、年度发行趋势、管理人和托管人集中度，以及运作方式等关键指标的可视化成果，并进一步说明了系统化展示的价值。

3.3.1 基金类型分布

基金类型的分布能够反映出市场整体的风险偏好与投资风格[9]。通过对提取结果进行标准化处理，我们得到各类基金的发行占比情况，如图 7 所示。

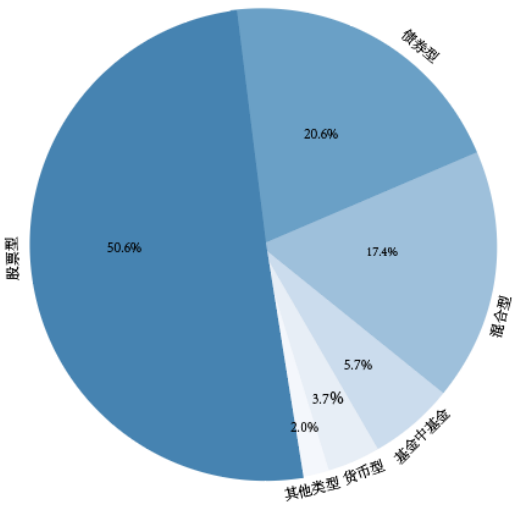


图 7 各类基金发行占比

结果表明，股票型及股票/指数类基金占据了市场的主体地位，其发行数量与占比均明显高于债券型、混合型、FOF 等其他类型基金。这一格局说明：

1、投资者对权益类资产的配置需求依旧旺盛，追求更高的潜在收益

2、指数类产品（如 ETF）近年来快速发展，逐渐成为市场创新与多样化配置的重要方向；

3、REITs 与 FOF 等新兴基金类型发行数量较少，表明其处于发展初期，但未来有较大潜力。

3.3.2 年度发行趋势

基金的年度发行数量能够反映市场景气度及政策导向。统计结果如图 8 所示，基金发行数量整体呈现上升趋势，并在部分年份出现高峰。这一特征表明基金市场的扩张与宏观经济环境密切相关：在金融市场活跃、资本市场行情走强时，基金发行量显著增加；在经济低迷或监管趋严的年份，发行数量相对收缩。



图 8 2000 年-2025 年基金发行数量折线图

年度发行数量可以表示为：

$$Y_t = \sum_{i=1}^{N} 1(year(T_i) = t) \tag{26}$$

其中，T_i表示基金i的发行时间，$1(\cdot)$为指示函数，当基金发行年份等于t时取值1，否则为0，通过该建模方式，可以将年度发行数量看作时间序列，为后续趋势预测提供基础。进一步而言，若对时间序列$\{Y_t\}$进行平稳化处理，还可以构建 ARIMA 或指数平滑模型，以对未来基金发行趋势进行预测。这说明该数据不仅有描述性意义，还可扩展为预测性分析。

3.3.3 基金管理人与托管人分析

基金管理人和托管人是基金行业的重要参与者，其分布与集中度直接决定了市场的竞争格局。

（1）基金管理人分析

统计结果（见图 9）表明，头部基金公司在新基金发行数量上具有明显优势，呈现出“强者恒强”的格局。这种集中效应表明行业资源、人才与渠道主要集中在少数大型机构。

为定量衡量集中度，本文引入赫芬达尔–赫希曼指数（*HHI*）：

$$HHI = \sum_{j=1}^{M} \left(\frac{n_j}{N} \right)^2 \tag{27}$$

其中，n_j表示管理人j的基金发行数量，M为管理人总数，N为全部基金数。*HHI* 越大，市场越集中。根据国际惯例，若*HHI*大于0.25，则市场被认为具有较高集中度。

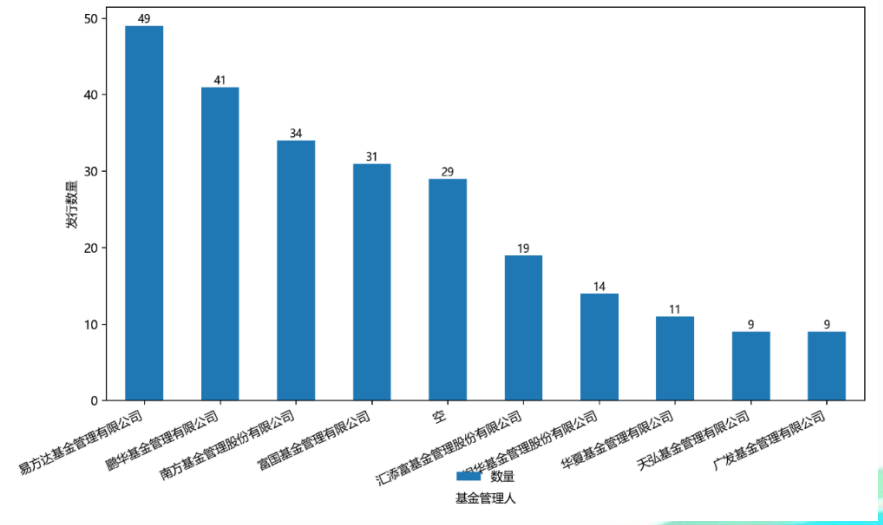


图 9 基金管理人发行数量

（2）从托管人分布来看（见图 10），大型商业银行如招商银行、兴业银行、平安银行等占据绝对主导地位。这说明托管业务高度依赖金融机构的综合实力和风控能力。托管市场的集中度同样可用 *HHI* 衡量，其结果进一步印证了托管业务的高度集中性。

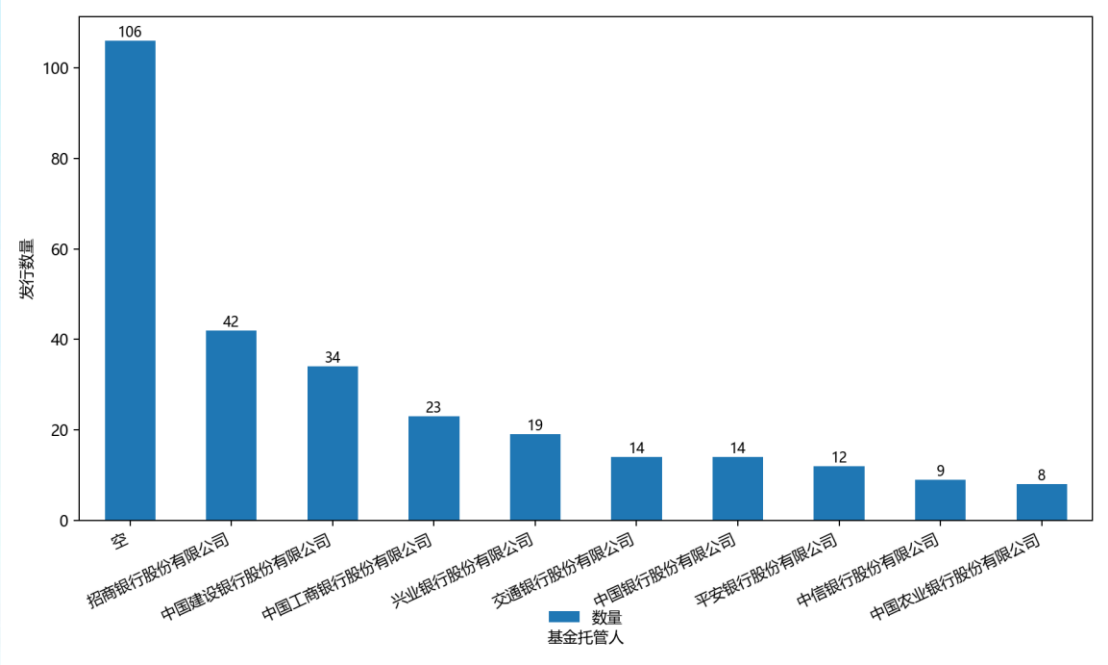


图 10 基金托管人发行数量

3.3.4 运作方式分布

基金的运作方式主要分为开放式基金与封闭式基金两类，其中开放式基金由于具备较高流动性，更符合大多数投资者的需求[10]。统计结果如图 11 所

示，开放式基金在数量与占比上均大幅领先，封闭式基金数量则相对有限。

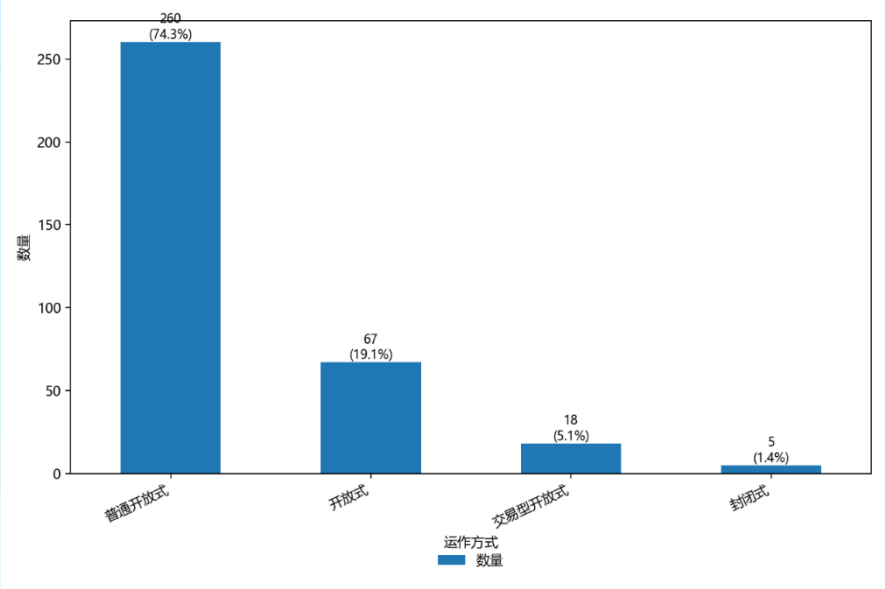


图 11 基金的运作方式数量统

运作方式的市场占比同样可用概率分布表示：

$$Q_i = \frac{m_i}{M} \quad ,i\epsilon\{\text{开放式，封闭式}\} \tag{28}$$

其中m_i为某运作方式基金数量，M为总基金数量。结果表明，开放式基金占比远大于封闭式基金，占比超90%。

这一特征揭示了我国公募基金市场的流动性偏好，也反映出投资者更倾向于在需要时赎回或调整资产配置的灵活性需求。

四、应用价值

4.1 经济效益分析

4.1.1 提升信息处理效率，降低人力成本

传统的基金公告信息处理主要依赖人工提取方式，需要专业人员花费大量时间阅读和整理文档。以一家中型金融机构为例，每日需要处理约 50 份新发公告，仅人工审核和录入就需要投入 3-4 名专业人员，平均每份公告处理时间超过 30 分钟。本项目开发的自动化信息提取系统能够将单份公告的处理时间缩短

至 5 分钟以内，效率提升超过 80%，显著降低了金融机构的人力成本投入。按当前金融行业数据分析师的平均人力成本计算，单家机构每年可节约人力成本约 100-150 万元。对于大型金融机构或数据服务商而言，由于其处理量更大，经济效益将更为显著。

4.1.2 增强数据时效性，提升决策价值

在金融投资领域，信息的时效性直接关系到其经济价值[11]。传统人工处理方式下，从公告发布到结构化数据可用的时间延迟通常为 2-3 个工作日，错过了最佳的投资决策窗口期。本系统能够实现公告发布后的实时处理，将数据准备时间缩短至小时级别，极大地提升了数据的商业价值。以新发基金认购为例，提前一天获取完整的结构化产品信息，可以帮助投资者更早进行产品评估和投资决策，在热门产品认购中占据先机。据估算，对于基金销售机构而言，信息获取时效性每提升 24 小时，可带来约 5-15%的销售增量。

4.1.3 支持规模化应用，产生规模效应

本系统的另一个重要经济效益体现在其可扩展性方面。传统人工处理模式难以应对业务量的大幅增长，而自动化系统只需增加计算资源即可快速扩展处理能力。这种特性使得金融机构在业务增长时无需同比增加人力投入，实现了显著的规模经济效益。对于万得、同花顺等金融数据服务商而言，采用本系统后可以在不增加人力成本的情况下，将数据处理能力提升数倍，从而支持更多元化的数据产品和服务创新，开辟新的收入增长点。据初步估算，大型数据服务商采用本系统后，每年可因此增加数百万元的营业收入。

4.1.4 优化资源配置，提升核心竞争力

通过应用本系统，金融机构可以将原有人力资源从繁琐的数据处理工作中解放出来，转向更高价值的投资分析、策略研究和产品创新等工作。这种资源配置的优化不仅直接降低了运营成本，更重要的是提升了机构的整体创新能力和核心竞争力。在金融行业同质化竞争日益激烈的背景下，这种基于技术赋能的核心能力提升，将为机构带来长期的经济效益和市场竞争优势。同时，系统

提供的高质量结构化数据也为后续的数据挖掘和智能分析应用奠定了基础，开启了更多增值服务的可能性，形成了良性的经济效益循环。

4.2 社会效益

4.2.1 提升金融市场信息透明度，保护投资者权益

本项目通过智能化的信息提取技术，将原本晦涩难懂的非结构化公告信息转化为标准、易用的结构化数据，极大地降低了普通投资者获取和理解关键信息的门槛[12]。系统能够自动提取并标准化呈现基金产品的费率结构、风险等级、管理人资质、投资范围等核心要素，使投资者无需具备专业的金融知识也能快速把握产品要点。这种信息获取方式的革新，有效解决了长期存在于金融市场中的信息不对称问题，使投资者能够基于充分、准确的信息做出理性的投资决策，避免因信息缺失或理解偏差导致的投资损失。同时，标准化的数据格式使得不同产品之间的比较变得更加便捷，促进了产品间的公平竞争，推动基金管理人不断提升产品质量和服务水平，从而构建一个更加透明、公正、健康的金融市场生态环境。

4.2.2 赋能监管科技，提升监管效能

该系统为金融监管部门提供了强大的技术工具，实现了监管模式的智能化升级。传统依赖人工抽检的监管方式不仅效率低下，而且覆盖面有限，难以应对日益增长的公告数量和信息复杂度[13]。本技术能够对全市场海量公告进行自动化、全天候的监测与解析，通过自然语言处理和数据分析技术，智能识别信息披露中的异常模式、逻辑矛盾或潜在违规线索。例如，系统可以自动比对同一基金管理人不同公告中的关键数据一致性，或识别费率披露是否符合监管要求。这种智能监管模式极大地扩展了监管覆盖面，提高了监管效率，推动监管模式从被动的"事后惩处"向主动的"事中监测"和"事前预警"转变，显著增强了监管的穿透性和精准性，为防范系统性金融风险提供了有力的技术支撑。

4.2.3 促进金融知识普及与投资者教育

系统提取出的清晰、直观的结构化数据，为金融知识普及和投资者教育提供了优质的素材基础。这些经过标准化处理的数据非常适合用于生成各种投资者教育材料，如产品比较指南、投资决策手册、风险教育读本等。教育机构和媒体可以基于这些数据开发交互式的投教应用，通过数据可视化、情景模拟等方式，帮助公众更直观地理解基金产品的运作机制、风险特征和市场动态。此外，这些结构化数据还可以支持学术研究和市场分析，为投资者教育提供更加科学、准确的依据。通过降低金融知识的获取门槛和理解难度，本项目不仅帮助投资者做出更明智的投资决策，更有助于提升社会整体的金融素养水平，培养理性的投资文化，为金融市场的长期健康发展奠定坚实的基础。

五、系统优化与展望

基于本研究实现的基金公告信息提取系统，我们认识到其在技术深度和应用广度上仍具有显著的提升空间。未来我们将从技术创新、功能扩展和应用深化三个维度持续推进系统的优化升级。

在技术创新方面，我们将重点探索深度学习技术的深度融合应用。计划引入基于 Transformer 架构的预训练语言模型，如 BERT、ERNIE 等领域适配模型，以增强系统对复杂语义语境和专业化表述的理解能力。通过大规模无监督预训练结合有监督微调，显著提升模型在金融领域的语义理解精度，有效解决当前规则方法在处理术语变异、同义表述等复杂语言现象时的局限性。同时，我们将研发多模态信息融合技术，综合分析文档的文本内容、版面布局、字体样式等视觉特征，构建更加鲁棒的信息提取模型。这种多模态方法将特别有助于处理表格复杂、排版多样的公告文档，提高关键数据的捕获率和准确率。

在功能扩展层面，系统将突破当前单一类型公告处理的限制，逐步扩展支持更多类型的金融文档。包括但不限于基金定期报告、临时公告、募集说明书更新文件等，最终形成覆盖全类型基金文档的自动化处理能力。我们还将开发实时监控与智能预警功能，通过建立异常检测模型和趋势分析算法，实现对市场动态的即时感知和风险预警。这套系统将能够自动识别信息披露中的异常模式，为监管机构和投资者提供及时的决策支持[14]。

在应用深化方面，我们将致力于构建开放式的数据服务平台。通过设计标准化的 API 接口，支持与各类金融分析平台、投资研究系统的数据对接和功能集成。这将使我们的技术成果能够赋能更广泛的金融应用场景，形成完整的智能投研生态系统。同时，我们计划开发个性化配置功能，允许用户根据特定需求自定义提取字段和处理规则，提升系统的适应性和灵活性。

通过这些系统化的优化升级，我们的目标是将当前的信息提取工具演进为支撑智能投研、监管科技和投资者服务的综合型基础设施。这不仅能够进一步提升信息处理的效率和准确性，更重要的是将为金融行业的数字化转型和智能化升级提供坚实的技术支撑，推动整个行业向更加高效、透明、智能的方向发展。

参考文献

[1] 中国证券投资基金业协会. 公募基金市场数据 [EB/OL]. (2024-01-23). [引用日期 2025-09-17]. https://www.amac.org.cn/sjtj/.

[2] 李莎.A 公募基金管理公司营销策略优化研究[D].郑州大学,2018.

[3] Vamvourellis D, Toth M, Desai D, et al. Learning mutual fund categorization using natural language processing[C]//Proceedings of the Third ACM International Conference on AI in Finance. 2022: 87-95.

[4] 李安兰,陈见丽.我国股票发行审核制度比较分析——兼论我国注册制的完善[J]. 中国注册会计师,2020,(05):76-80.DOI:10.16292/j.cnki.issn1009-6345.2020.05.010.

[5] 张佳.基于知识图谱的预算执行审计智能问答系统的设计与实现[D].北京交通大学,2024.DOI:10.26944/d.cnki.gbfju.2024.000567.

[6] 喻华丽,曾海泉.证券市场文本信息智能化应用与实践[J].金融电子化,2020,(10):71-73.DOI:CNKI:SUN:JRDZ.0.2020-10-033.

[7] Navigating the Landscape of Automated Information Extraction for Financial Fund Prospectuses: Survey and Challenges.

[8] 王宁.中国公募基金信息披露制度相关问题研究[D].上海财经大学,2021.DOI:10.27296/d.cnki.gshcu.2021.001666.

[9] 吕世瑞.中国机构投资者投资分散不足的实证检验[D].青岛大学,2007.

[10] 程勇.我国开放式股票型基金投资风格漂移及其对绩效影响研究[D].重庆大学,2016.

[11] 黄堉宇.上市公司信息披露操纵动机研究：基于数字和文本操纵的比较视角[J].商业会计,2025,(17):90-93.DOI:CNKI:SUN:SYKI.0.2025-17-014.

[12] 刘灿,黄晨.数字化背景下会计信息披露方式的演进与监管挑战分析[J].中国集体经济,2025,(15):81-84.DOI:10.20187/j.cnki.cn/11-3946/f.2025.15.006.

[13] 李钊.数字金融对企业金融行为的影响研究[D].四川大学,2024.DOI:10.27342/d.cnki.gscdu.2024.000008.

[14] 刘之一.基于人工智能的品牌价值评估模型构建与管理信息披露研究[J].中国品牌与防伪,2025,(07):168-170.DOI:CNKI:SUN:ZGFW.0.2025-07-055.